

Mownit Interpolacja

Magdalena Kozub

4.05.2019

1. Napisać własną implementację interpolacji wielomianowej stosując wprost wzór na wielomian interpolacyjny Lagrange'a. Język implementacji do wyboru (Julia, C). Przetestować swoją implementację na wylosowanych węzłach interpolacji w wybranym przedziale. Narysować wykres wielomianu interpolacyjnego w tym przedziale wraz z węzłami interpolacji.

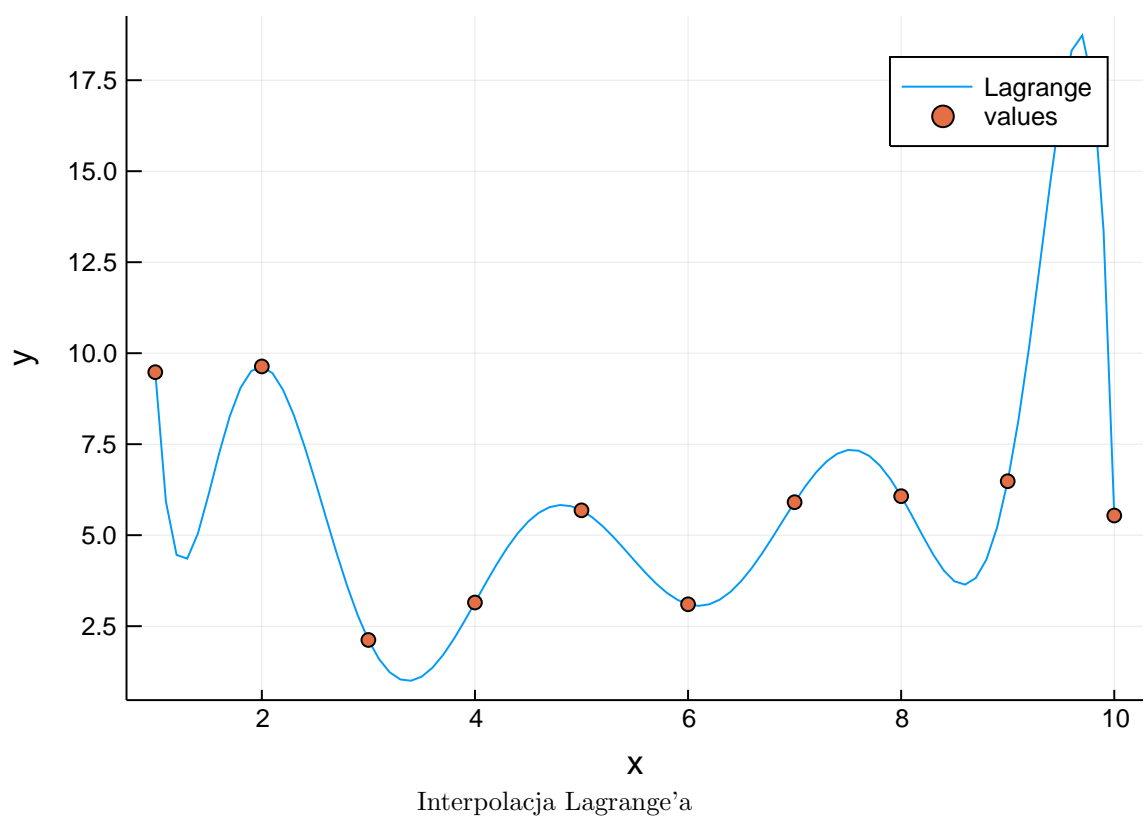
Aby obliczyć współczynniki wielomianu interpolującego stosując metodę Lagrange'a należy podstawić do wzoru na wielomian interpolacyjny Lagrange'a wartości danych punktów:

$$L_j(x) = \frac{d}{m} = \prod_{j=0, j \neq i}^n \frac{x - x_j}{x_i - x_j}, \quad P_n(x) = \sum_{j=0}^n L_j(x) * f(x_j)$$

Na początku wybieramy punkty o losowych wartościach, a następnie dla każdego x z podanego przedziału obliczamy wartości wielomianu Lagrange'a.

```
#Interpolacja Lagrange'a
function Lagrange(X, Y, xi)
    n = length(X)
    result = 0
    for i=1:n
        term = Y[i]
        for j=1:n
            if i != j
                term=term*(xi - X[j])/(X[i]-X[j])
            end
        end
        result += term
    end
    return result
end
```

Listing 1: Kod Interpolacji Lagrange'a w języku Julia



2. Zrobić to samo dla metody Newtona (metoda ilorazów różnicowych). Zadbaj o to, żeby ilorazy wyliczać tylko raz dla danego zbioru węzłów interpolacji. Jezyk implementacji wybrać taki sam, jak w poprzednim punkcie. Narysować wykres wielomianu interpolacyjnego dla tych samych danych, co w poprzednim punkcie.

Aby obliczyć współczynniki wielomianu interpolacyjnego metoda Newtona potrzebujemy obliczyć najpierw ilorazy skończone dla danych punktów, których wartości wyliczyliśmy wcześniej. Następnie korzystamy ze wzoru na interpolacyjny wzór Newtona:

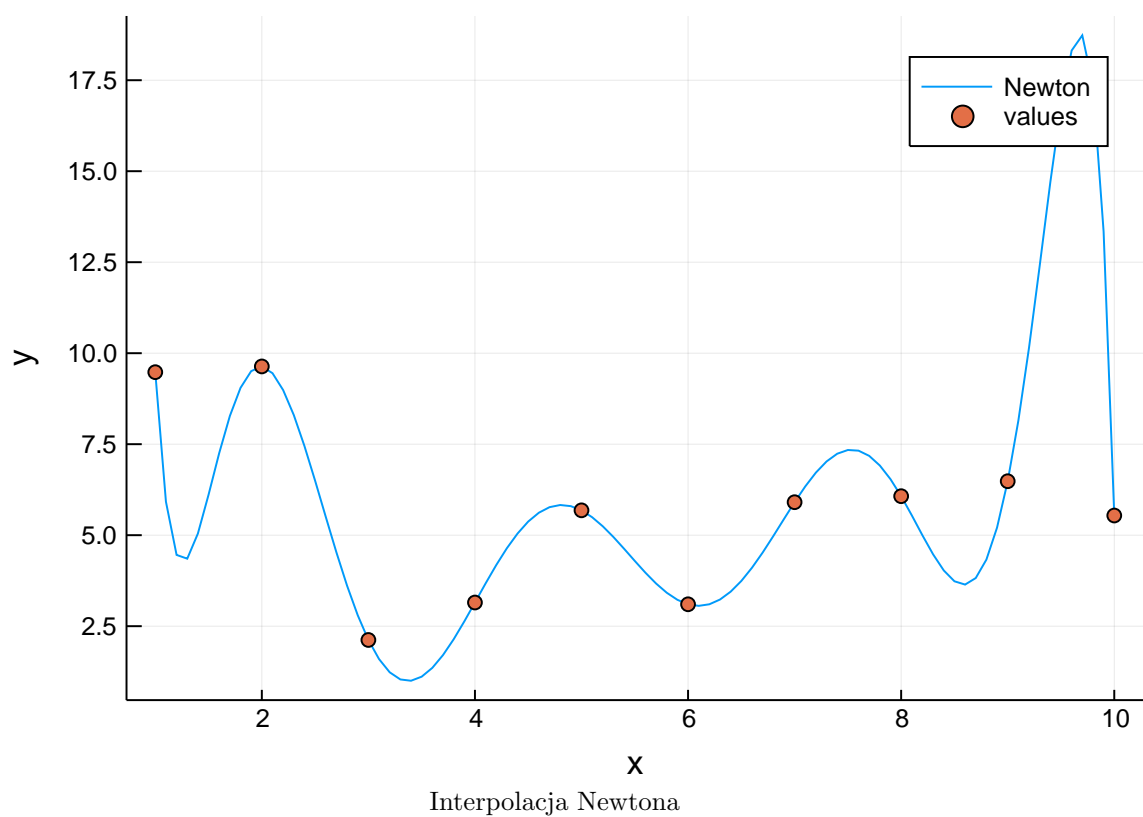
$$P_n(x) = f[x_0] + \sum_{k=1}^n [x_0, x_1, \dots, x_k] * (x - x_0) * \dots * (x - x_{k-1})$$

K-ty iloraz różnicowy wyliczamy ze wzoru:

$$f[x_i, x_{i+1}, \dots, x_{i+k}] = \frac{f[x_{i+1}, x_{i+2}, \dots, x_{i+k}] - f[x_i, x_{i+1}, \dots, x_{i+k-1}]}{x_{i+k} - x_i}$$

```
#Interpolacja Newtona
function diffs(X, Y, i)
    n = length(X)
    M = zeros(n)
    for j=1:n-i
        M[j]=(Y[j + 1, i + 1] - Y[j, i + 1])/(X[j + i] - X[j])
    end
    Y[:,2+i] = M
end
function Newton(X, Y)
    n = length(X)
    M=zeros(n, n+2)
    M[:,1] = X
    M[:,2] = Y
    for i=1:n
        diffs(X, M, i)
    end
    return M
end
function Value(Coefs, xi)
    sum = Coefs[1,2]
    n = length(Coefs[:,1]) - 1
    for i=1:n
        prod = Coefs[1, i + 2]
        for j=1:i
            prod *= (xi - Coefs[j,1])
        end
        sum += prod
    end
    return sum
end
```

Listing 2: Kod Interpolacji Newtona w języku Julia

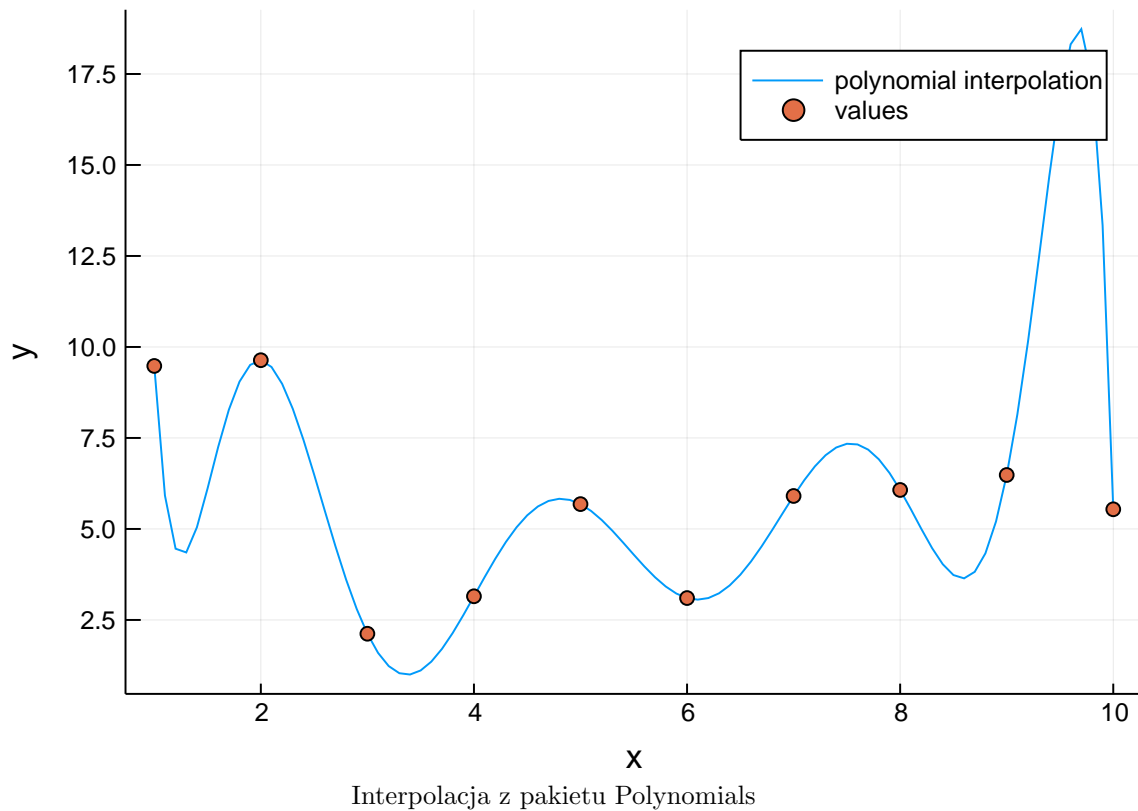



3. Zastosować interpolację wielomianową z pakietu Polynomials (jeśli wybraliśmy Julie) albo z funkcji `gsl_interp_polynomial` z pakietu GSL (jeśli wybraliśmy C) do tych samych danych, co w poprzednich punktach. Porównać wszystkie 3 wyniki interpolacji wielomianowej na jednym wykresie. Co zauważamy? Dlaczego?

```
#Interpolacja z pakietu Polynomials
fit1=polyfit(x, f_x)
p_ys = [fit1(x) for x in xs]

plot(xs, p_ys, label="polynomial interpolation", xlabel="x", ylabel="y")
w1 = scatter!(x, f_x, label="values", xlabel="x", ylabel="y")
```

Listing 3: Kod Interpolacji z pakietu Polynomials w języku Julia





Porównanie 3 sposobów interpolacji

Jak można zauważyć na powyższym wykresie wielomiany interpolujące są dokładnie identyczne bez względu na to, która metoda je wyliczyliśmy. Zgadza się to z twierdzeniem o jednoznaczności wielomianu interpolacyjnego, który mówi, że istnieje dokładnie jeden taki wielomian dla podanych węzłów.

4. Porównać metody poprzez pomiar czasu wykonania dla zmiennej ilości węzłów interpolacji. Dokonać pomiaru 10 razy i policzyć wartość średnią oraz oszacować błąd pomiaru za pomocą odchylenia standardowego. Narzędzie do analizy danych do wyboru (Julia, R).

```
using DataFrames
using Polynomials
using Statistics

function NewtonWrapper(x, f_x, x_s)
    dif = Newton(x, f_x)
    [Value(dif, xi) for xi in x_s]
end
function PolyWrapper(x, f_x, x_s)
    fit1=polyfit(x, f_x)
    [fit1(x) for x in x_s]
end

df1=DataFrame(size = Int[], lagrange = Float64[], newton = Float64[], poly = Float64[])
for i=10:10:100
    for j=1:10
        x = 1:i
        f_x = rand(i)
        xs = 1:0.1:i

        lagrange = @elapsed [Lagrange(x, f_x, xi) for xi in xs]
        newton = @elapsed NewtonWrapper(x, f_x, xs)
        poly = @elapsed PolyWrapper(x, f_x, xs)

        push!(df1, [i lagrange newton poly])
    end
end

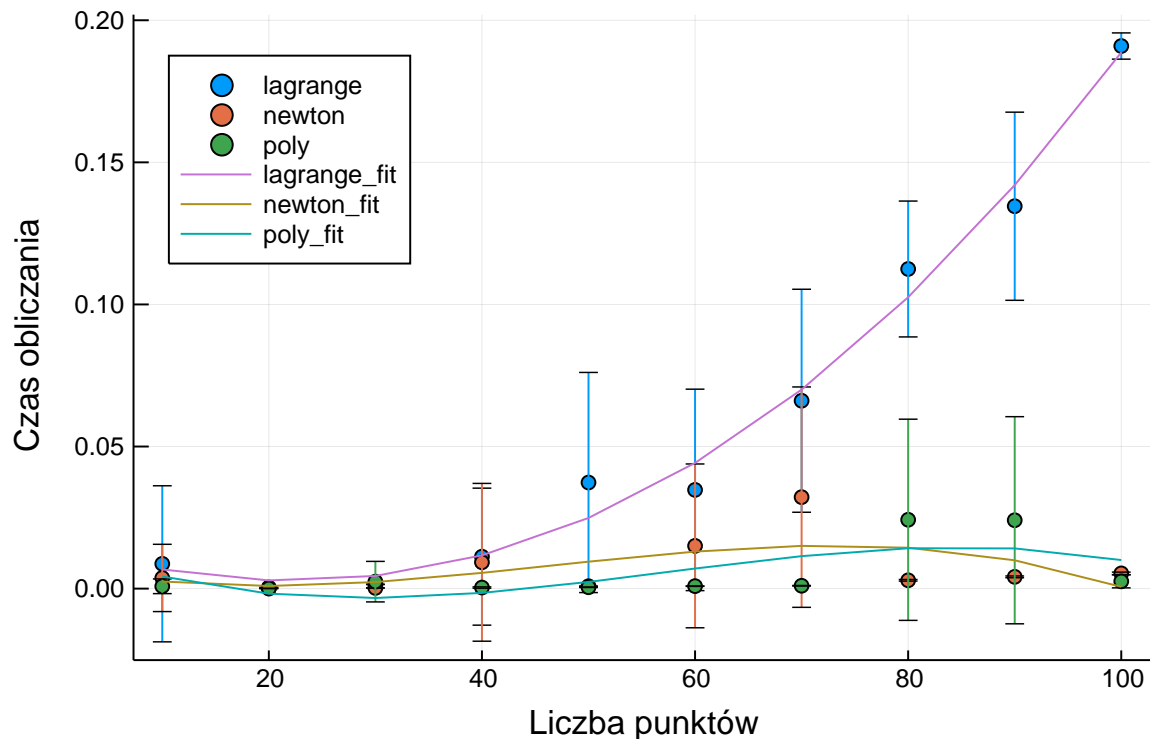
df2 = by(df1, :size, df->DataFrame(lagrange_mean=mean(df[:lagrange]),
    lagrange_std=std(df[:lagrange]),
    newton_mean=mean(df[:newton]), newton_std=std(df[:newton]),
    poly_mean=mean(df[:poly]),
    poly_std=std(df[:poly])))
lagrange_fit=polyfit(df2[:size], df2[:lagrange_mean], 3)
newton_fit=polyfit(df2[:size], df2[:newton_mean], 3)
poly_fit=polyfit(df2[:size], df2[:poly_mean], 3)

w1 = scatter(df2[:size], [df2[:lagrange_mean], df2[:newton_mean], df2[:poly_mean]],
    yerr=[df2[:lagrange_std] df2[:newton_std]
    df2[:poly_std]], label=["lagrange" "newton" "poly"],
    legend=:topleft)

plot!(df2[:size], polyval(lagrange_fit, df2[:size]), label="lagrange_fit")
plot!(df2[:size], polyval(newton_fit, df2[:size]), label="newton_fit")
plot!(df2[:size], polyval(poly_fit, df2[:size]), label="poly_fit")
```

Listing 4: Kod wyliczający czas działania każdej z interpolacji

Porównanie interpolacji



Porównanie czasów działania 3 rodzajów interpolacji

Najwolniejsza interpolacja okazała się być interpolacja Lagrange'a, szczególnie dla większej liczby punktów. Interpolacja Newtona i z pakietu Polynomials osiągały podobne wyniki.

5. Poeksperymentować z interpolacją funkcjami sklejanymi (minimum dwie różne funkcje sklepane), narysować wykresy i porównać z wykresami interpolacji wielomianowej.

Porównałam dwie funkcje sklepane - kwadratowa oraz kubiczna (sześcienna).

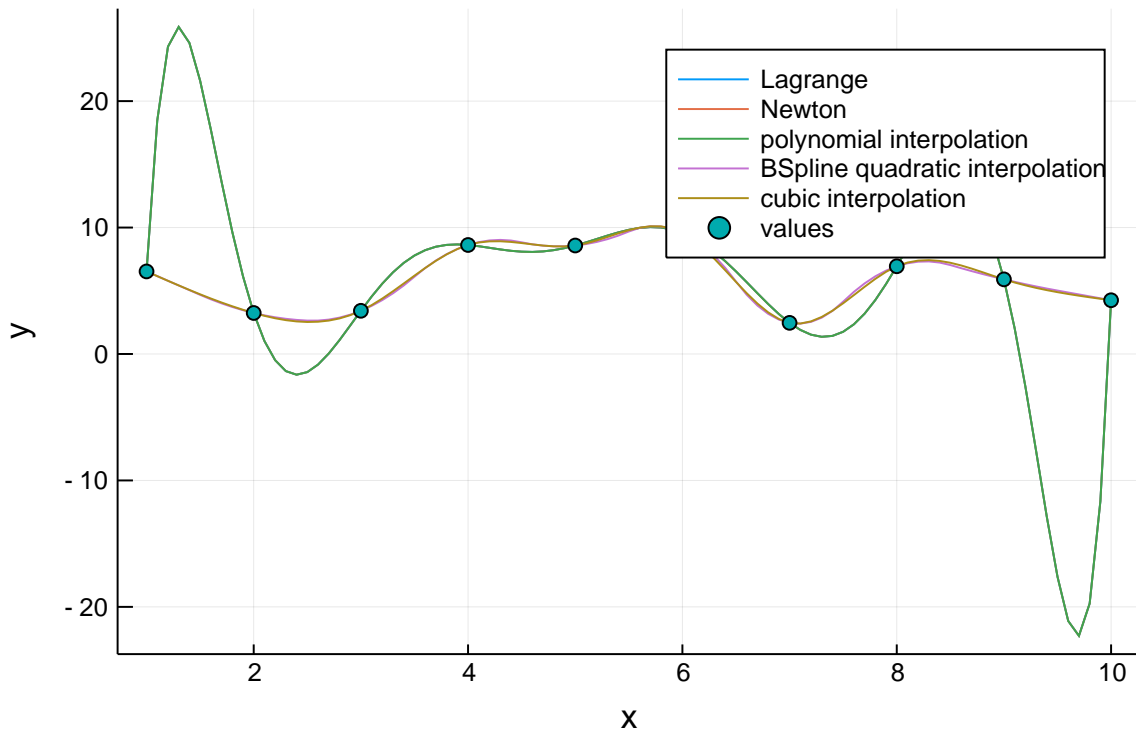
```
using Interpolations

x = 1:10
f_x = rand(10) * 10
xs = 1:0.1:10
l_ys = [Lagrange(x, f_x, xi) for xi in xs]
dif = Newton(x, f_x)
n_ys = [Value(dif, xi) for xi in xs]
fit1=polyfit(x, f_x)
p_ys = [fit1(x) for x in xs]
itp = interpolate(f_x, BSpline(Quadratic(Line(OnCell()))))
q_ys = [itp(xi) for xi in xs]
interp_cubic = CubicSplineInterpolation(x, f_x)
c_ys = [interp_cubic(xi) for xi in xs]

plot(xs, l_ys, label="Lagrange")
plot!(xs, n_ys, label="Newton")
plot!(xs, p_ys, label="polynomial interpolation")
plot!(xs, q_ys, label="BSpline quadratic interpolation")
plot!(xs, c_ys, label="cubic interpolation")
w1 = scatter!(x, f_x, label="values")
```

Listing 5: Kod Interpolacji oraz funkcji sklepanych w języku Julia

Porównanie interpolacji



Porównanie wielomianów interpolacyjnych i funkcji sklepanych

Jak można zauważyć używając funkcji sklepanych nie występuje efekt Rungego, który pojawił się na końcach przedziału dla wielomianów interpolacyjnych. Interpolacja wielomianami jednak dość dobrze przybliża wartości w środku przedziału. Użycie funkcji sklepanej kwadratowej daje w wyniku dokładny wielomian interpolacyjny, jednak mniej dokładny i mniej gładki niż gdy użyjemy sześcienniej funkcji sklepanej, dlatego w praktyce częściej wykorzystujemy funkcje kubiczne.

6. Zademonstrować efekt Rungego.

Efekt Rungego polega na obniżeniu jakości interpolacji pomimo zwiększenia liczby węzłów, tzn. początkowo wraz ze wzrostem liczby węzłów jakość interpolacji rośnie (błąd maleje), ale potem pogarsza się (szczególnie na końcach przedziału i dla wielomianów interpolujących wysokich stopni). Występuje wtedy kiedy używamy interpolacji wielomianowej i jednocześnie nakładamy warunek równoodległości węzłów.

```
function f(x)
    return 1/(1+25*x^2)
end

x = -1:0.125:1
f_x = [f(xi) for xi in x]

xs = -1:0.005:1
fit1 = polyfit(x, f_x)
p_ys = [fit1(x) for x in xs]
```

```

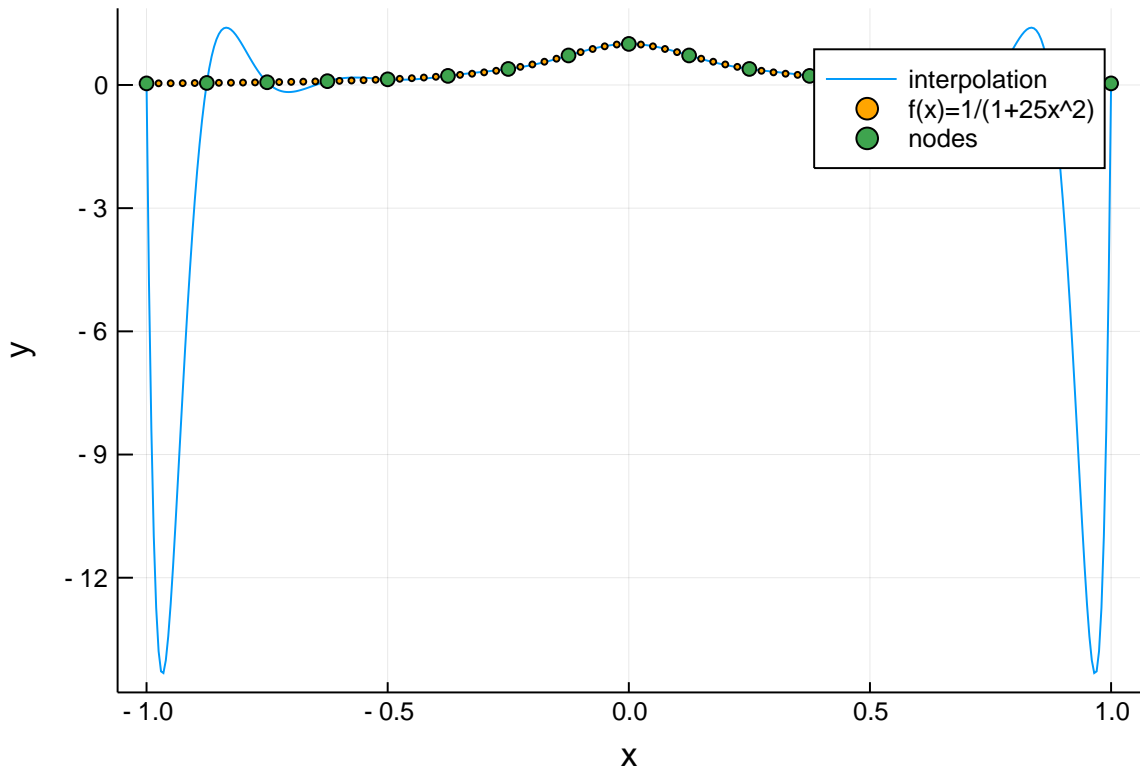
f_xs = -1:0.025:1
f_ys = [f(x) for x in f_xs]

println(fit1)

plot(xs, p_ys, label="interpolation")
scatter!(f_xs, f_ys, label="f(x)=1/(1+25x^2)", color="orange", marker = (:dot, 2))
w1 = scatter!(x, f_x, label="nodes")

```

Listing 6: Kod efektu Rungego w języku Julia



Wykres przedstawiający efekt Rungego